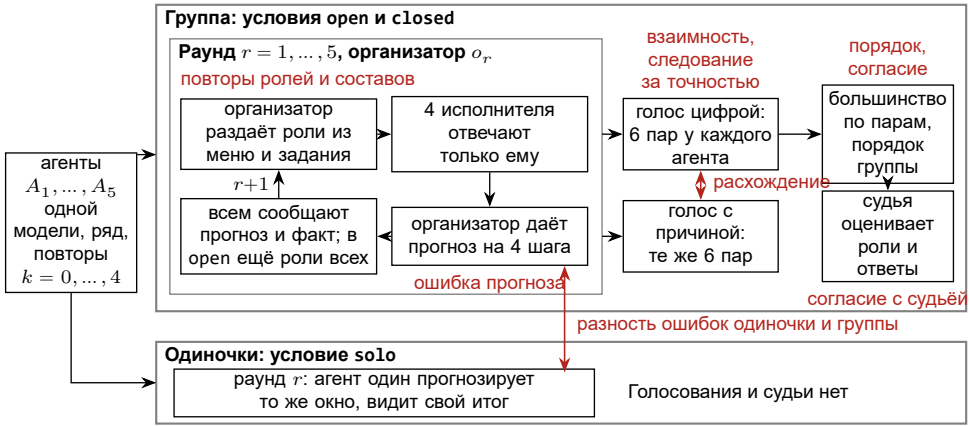
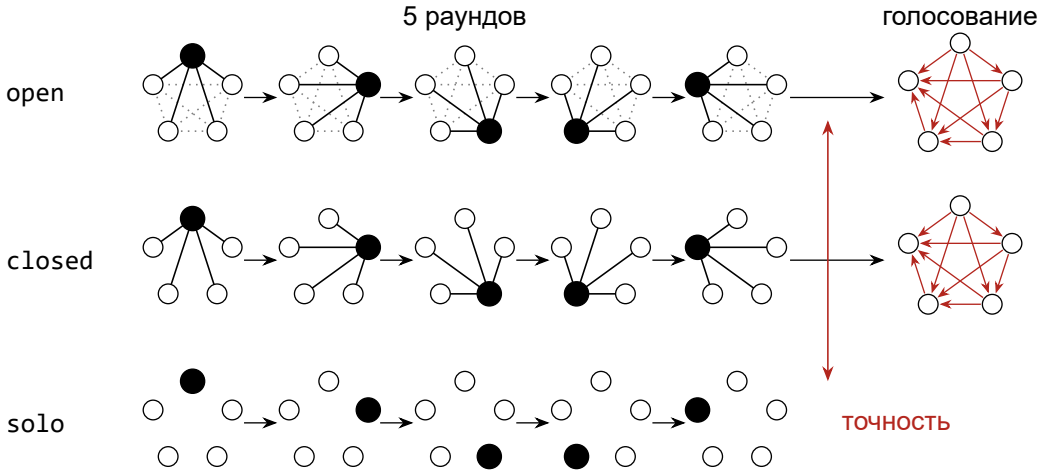
Весь эксперимент на одной схеме



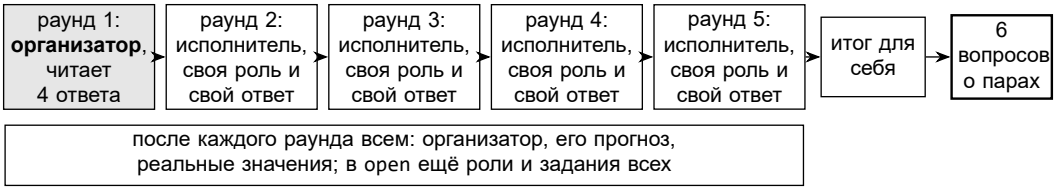
Голос цифрой и голос с причиной агент даёт по одной и той же истории, и ни один из этих ответов в неё не попадает. Здесь r — номер раунда, k — номер повтора, o_r — организатор раунда r, равный $A_{((r+k-1) \bmod 5)+1}$, а окно — четыре шага ряда, которые прогнозируются в раунде. Рамка запуска повторяется для каждого условия и каждого k; в `solo` порядок агентов и окна те же. Красным показаны измеряемые величины.

Схема эксперимента



Чёрный — организатор раунда; линии — задания и ответы; пунктир — роли видны всем; стрелки — победы в парах.

Что агент знает в момент голосования



Показан агент, организующий раунд 1; у остальных агентов серым выделен другой раунд.

В памяти есть

прогноз каждого организатора и факт, поэтому точность агент может вычислить сам;

роль и ответ агента в каждом раунде, а также 4 ответа в раунде, который он вёл;

сообщение, что работу оценивают внешние эксперты.

В памяти нет

ответов исполнителей в чужих раундах;

чужих ролей в `closed`, кроме розданных им самим;

готовых значений ошибки и оценок судьи;

предупреждения о голосовании до самого вопроса.

Вопросы о ролях и точности

Вопрос	Величина и уровень сравнения
Закрепляются ли роли за агентами?	F — сколько раз агент снова получил прежнюю роль; сравниваем со случайной раздачей тех же ролей
Передаётся ли состав ролей?	C — сколько раз набор ролей раунда совпал с набором предыдущего; сравниваем с независимым выбором наборов
Точнее ли группа одиночки?	MASE — ошибка прогноза, делённая на ошибку прогноза «как на прошлой неделе»; ΔQ — MASE одиночки минус MASE группы на том же окне

Здесь p — вероятность при нулевой гипотезе получить значение не меньше наблюдаемого. Формулы — в запасных слайдах.

Вопросы о голосовании

Вопрос	Величина и уровень сравнения
Складываются ли голоса в порядок без циклов?	h — доля троек агентов без цикла в итоге попарного большинства; сравниваем со случайными голосующими
Согласны ли агенты, кто должен руководить?	U — среднее по запускам число пар кандидатов, которые трое голосующих решили одинаково; сравниваем со случайными голосующими. L — число запусков, где лидирует самый частый лидер; сравниваем со сменой имён агентов
Взаимны ли предпочтения?	τ^{rec} — согласие мест, которые два агента дают друг другу; сравниваем с одними общими предпочтениями
Следует ли голос за точностью?	τ^{acc} — согласие порядка голосующего с порядком агентов по ошибке; H — сколько голосующих поставили первым самого точного; сравниваем с перемешанными ошибками
Следует ли голос за оценкой судьи?	τ^{J} — согласие порядка голосующего с порядком организаторов по оценке судьи за распределение ролей; сравниваем с перемешанными оценками

Здесь τ — коэффициент Кендалла между двумя порядками.

Результаты: роли и точность

Если назначения видны всем, агент обычно снова получает прежнюю роль. Из 75 возможных случаев так происходит 67, 64 и 69 раз в `open` и 28, 39 и 33 раза в `closed` (старшая Gemma, Qwen, YandexGPT), тогда как случайная раздача тех же ролей даёт от 12 до 17 раз. На младшей Gemma получено 33 из 45 в `open` и 9 из 30 в `closed`, на DeepSeek 12 из 15 в `open`.

Организаторы не перенимают набор ролей друг у друга. Набор совпадает с предыдущим не чаще, чем при независимом выборе: наименьшее p по всем запускам равно $0{,}077$.

Группа прогнозирует не точнее одиночки. На одном и том же окне группа точнее в 23 случаях из 50 на старшей Gemma ($p = 0{,}67$), в 22 из 50 на YandexGPT ($p = 0{,}77$) и в 11 из 25 на младшей Gemma ($p = 0{,}69$). На Qwen она точнее только в 17 случаях из 50 ($p = 0{,}044$).

Результаты: голосование

Отсутствие циклов не отличает агентов от случайных голосующих. На полных сериях h лежит от $0{,}40$ до $1{,}00$, а у случайных голосующих 95% значений лежат от $0{,}60$ до $1{,}00$, поэтому при пяти агентах этот показатель почти ничего не различает.

Внутри запуска агенты чаще случайного выбирают одного и того же кандидата. Каждую из 10 пар кандидатов решают трое остальных агентов. Все трое выбирают одного кандидата в среднем в 4,4, 5,2 и 5,8 парах в `open` ($p \leq 0{,}006$) и в 2,4, 3,8 и 4,0 парах в `closed` ($p = 0{,}60$, $0{,}042$ и $0{,}024$), тогда как случайные голосующие дают 2,5 пары (порядок серий: старшая Gemma, Qwen, YandexGPT).

Лидер от запуска к запуску обычно меняется. Исключение одно: на YandexGPT в `open` агент A_3 лидирует в 4 запусках из 5 ($p = 0{,}006$).

Взаимность объясняется общими предпочтениями. Выше их уровня τ^{rec} поднимается только на старшей Gemma в `open` ($+0{,}31$ против $+0{,}13$), но превышение держится на одном запуске: без него $p = 0{,}145$.

Голос не следует за точностью прогноза. Самого точного организатора ставят первым 12, 13 и 11 голосующих из 50 при 12,5 у случайных; наименьшее p по условиям равно $0{,}266$, а с поправкой на трудность окна $0{,}074$.

Голос не следует за оценкой судьи. Средняя τ^{J} в `open` и `closed` равна $-0{,}01$ и $+0{,}01$ на старшей Gemma, $+0{,}07$ и $+0{,}17$ на Qwen, причём все $p \geq 0{,}299$. На YandexGPT судьёй была та же модель, и оценки различались лишь в 2 запусках из 10, поэтому вывода по ней нет.

Итог

Вопрос	Ответ
Закрепляются ли роли?	да, и сильнее при видимых назначениях
Передаётся ли состав ролей?	нет
Точнее ли группа одиночки?	нет; на Qwen группа хуже на границе значимости
Есть ли порядок без циклов?	не отличим от случайного, тест слабый
Согласны ли агенты о руководителе?	в запуске да, между повторами почти нет
Взаимны ли предпочтения?	объясняются общими предпочтениями
Следует ли голос за точностью?	нет
Следует ли голос за оценкой судьи?	нет; по YandexGPT вывода нет

Ограничения. На условие приходится пять повторов на одном временном ряду, поэтому слабые эффекты не обнаруживаются. Серии различаются моделью, а часть и языком промптов, так что напрямую мы их не сравниваем. Выводы о голосовании не распространяются на младшую Gemma, поскольку её голос отражает место кандидата в паре. Меню ролей и очерёдность организаторов заданы экспериментатором.

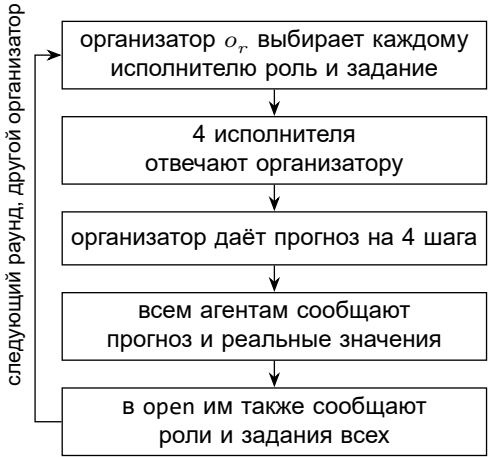
Какие условия можно добавить

Что меняем	Что узнаем
Зачем нужно закрепление ролей	
Виден набор ролей, но не видно, кому какая досталась	Если закрепление исчезнет, оно держалось на том, кто какую роль получал
Роли раздаёт среда: за агентом постоянно или заново в каждом раунде	Если постоянные роли дают меньшую ошибку, закрепление полезно для прогноза
Организатор опрашивает агентов без ролей	Если ошибка та же, роли ничего не добавляют
Откуда берутся закрепление и согласие	
Агент не помнит прошлых раундов, кроме их итогов	Если закрепление в `closed` исчезнет, оно шло от памяти агента
Перед голосованием агент не пишет итог для себя	Если голоса изменятся, этот итог влияет на выбор
Перед голосованием скрыты прогнозы и реальные значения	Если согласие сохранится, оно не опирается на итоги раундов
Что будет при большей свободе и разных агентах	
Следующего организатора выбирают голосованием	Появится ли устойчивый лидер, когда выбор влияет на работу
Агенты видят разные данные	Выберет ли группа агента с лучшими данными
Агенты пишут друг другу напрямую	Станет ли группа точнее одиночки без посредника

Выбор организатора голосованием нарушает очерёдность, так что с нынешними сериями по ΔQ его сравнить нельзя.

Запасные слайды

Один раунд в группе



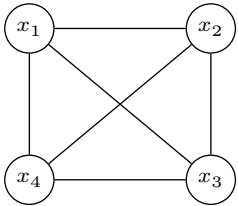
Что видит агент

	open	closed	solo
своя роль и задание	да	да	—
роли и задания всех	да	нет	—
ответы исполнителей	организатор		—
прогноз и факт	все	все	свои

Меню ролей

Историк, календарь, моделист, статистик, сценарист, критик. Организатор может дать одну роль нескольким исполнителям и не использовать часть ролей, но не может ввести новую.

Голосование



Голосующий v отвечает на 6 вопросов: по одному на каждое ребро графа K_4, вершины которого $x_1, \ldots, x_4$ — остальные агенты.

Вопрос. Кого из двух кандидатов назначить организатором прогноза на 13 шагов, по ходу которого проверок не будет? Голоса тайные, вопросы задаются от одного состояния памяти и в историю не попадают.

Голос цифрой. Агент отвечает одной цифрой. Пусть $P_v(x \mid \{x, y\})$ — вероятность, с которой v в паре кандидатов $\{x, y\}$ называет цифру кандидата x. Предпочтение равно

$$m_v(x, y) = \log P_v(x \mid \{x, y\}) - \log P_v(y \mid \{x, y\}).$$

Итог. Кандидат выигрывает пару, если за него больше голосов из трёх остальных агентов. Агенты упорядочены по числу выигранных пар.

Голос с причиной. Параллельно голосу цифрой те же пары задаются от той же истории агента. Ответ содержит выбор и причину. Отдельная проба задаёт одному агенту каждую его пару 5 раз.

Обозначения

Положим $\mathcal{A} = \{A_1, \dots, A_5\}$, а $\mathcal{R}$ — меню из шести ролей. Раунд r организует o_r, исполнители образуют множество $\mathcal{W}_r = \mathcal{A} \setminus \{o_r\}$, а $\rho_r(i) \in \mathcal{R}$ — роль исполнителя i.

Для голосующего v и кандидата $x \neq v$ суммарный перевес равен

$$s_v(x) = \sum_{y \notin \{v,x\}} m_v(x, y),$$

а $\pi_v(x) \in \{1, \dots, 4\}$ — место x в порядке убывания s_v.

Пусть $a(x)$ и $b(x)$ — места элемента x в двух порядках на множестве S. Коэффициент Кендалла равен

$$\tau(a, b) = \binom{|S|}{2}^{-1} \sum_{\{x,y\} \subset S} \mathrm{sgn}\big(a(x) - a(y)\big)\, \mathrm{sgn}\big(b(x) - b(y)\big).$$

Пусть T — наблюдаемая статистика, а T^* — её значение в одном из M розыгрышей нулевой гипотезы. Тогда $p = \dfrac{1 + \#\{T^* \geq T\}}{M + 1}$. Символ $\mathbf{1}[\cdot]$ обозначает индикатор, а единица анализа — запуск.

Закрепление ролей F

Пусть $\mathrm{prev}_r(i)$ — предыдущий раунд, в котором агент i был исполнителем. Число повторов равно

$$F = \sum_{r} \sum_{\substack{i \in \mathcal{W}_r \\ \mathrm{prev}_r(i)\ \text{определён}}} \mathbf{1}\big[\rho_r(i) = \rho_{\mathrm{prev}_r(i)}(i)\big], \qquad 0 \le F \le 15.$$

Нулевая гипотеза. В каждом раунде набор ролей $\{\rho_r(i)\}_{i \in \mathcal{W}_r}$ сохраняется и независимо переставляется между теми же исполнителями. Значение p одностороннее, $M = 20000$.

Эта гипотеза учитывает выбор ролей организаторами, поэтому F сверх него измеряет привязку роли к конкретному агенту.

Специализация агента i равна доле его назначений на самую частую роль:

$$\mathrm{sp}(i) = \max_{q \in \mathcal{R}} \frac{\#\{r : \rho_r(i) = q\}}{\#\{r : i \in \mathcal{W}_r\}}.$$

Повтор состава ролей C

Состав раунда — множество ролей без учёта кратности и исполнителей: $S_r = \{\rho_r(i) : i \in \mathcal{W}_r\} \subseteq \mathcal{R}$. Число повторов при смене организатора равно

$$C = \sum_{r=2}^{5} \mathbf{1}[S_r = S_{r-1}], \qquad 0 \le C \le 4.$$

Нулевая гипотеза. Составы $S_1^*, \dots, S_5^*$ независимо выбираются из эмпирического набора составов всех запусков того же условия и серии. Так повторы от общего предпочтения одного состава не считаются передачей схемы.

Пусть C^* — значение C в розыгрыше, а $\mathbb{E}C^*$ — его среднее по розыгрышам. Значение p двустороннее, $M = 20000$:

$$p = \frac{1 + \#\{|C^* - \mathbb{E}C^*| \ge |C - \mathbb{E}C^*|\}}{M + 1}.$$

Ошибка прогноза MASE

Пусть y_t — значение ряда на шаге t, а $t_r = 52 + 4(r-1)$. В раунде r агент видит историю $y_{t_r-51}, \dots, y_{t_r}$ и даёт прогноз $\widehat{y}_{t_r+1}, \dots, \widehat{y}_{t_r+4}$. Ошибка нормируется на ошибку наивного прогноза $\widehat{y}_{t+1} = y_t$ на видимой истории:

$$\mathrm{MASE}_r = \frac{\dfrac{1}{4}\displaystyle\sum_{j=1}^{4} \left|\widehat{y}_{t_r+j} - y_{t_r+j}\right|}{\dfrac{1}{51}\displaystyle\sum_{s=t_r-50}^{t_r} |y_s - y_{s-1}|}.$$

При $\mathrm{MASE}_r < 1$ прогноз точнее наивного на истории. Знаменатель зависит только от окна, поэтому внутри одного окна сравнение зависит только от числителя.

Эта величина зависит от трудности окна, поэтому условия сравниваются по ΔQ.

Коллективный выигрыш ΔQ

Пусть $\mathrm{MASE}^{c}_{k,r}$ — ошибка условия c в повторе k и раунде r. Для $c \in \{\texttt{open}, \texttt{closed}\}$ положим

$$\Delta Q_{c,k,r} = \mathrm{MASE}^{\texttt{solo}}_{k,r} - \mathrm{MASE}^{c}_{k,r}\,.$$

В этом сравнении совпадают окно и агент, ведущий раунд. При $\Delta Q > 0$ группа точнее.

Проверка. Пусть из n ненулевых разностей положительны n_+. Тест точный, знаковый и двусторонний:

$$p = \min\Bigg(1,\; 2 \cdot 2^{-n} \sum_{i=0}^{\min(n_+,\, n-n_+)} \binom{n}{i}\Bigg).$$

Пары внутри запуска зависимы, поэтому p — ориентировочная оценка.

Независимый ансамбль. Пусть $\hat{y}^{c}_{k,r,t}$ — прогноз условия c в повторе k и раунде r на шаг t. На каждом шаге берётся медиана по повторам, и по ней считается MASE:

$$\hat{y}^{\mathrm{med},c}_{r,t} = \mathrm{med}_k\, \hat{y}^{c}_{k,r,t}, \qquad c \in \{\texttt{open}, \texttt{closed}, \texttt{solo}\}.$$

Линейность порядка h

Кандидат x выигрывает пару $\{x, y\}$, если среди трёх голосующих $v \notin \{x, y\}$ больше тех, у кого $m_v(x, y) > 0$. Обозначим через $w(x)$ число пар, выигранных агентом x. Индекс Ландау равен

$$h = \binom{5}{3}^{-1} \sum_{x \in \mathcal{A}} \binom{w(x)}{2}.$$

При полном порядке без циклов $h = 1$, а каждая циклическая тройка уменьшает сумму. Пары без большинства не дают побед и тоже уменьшают h.

Нулевая гипотеза. Предпочтения каждого голосующего — независимый равномерно случайный порядок; из $M = 20000$ розыгрышей берутся среднее и 95%-интервал.

Сопутствующие величины: медиана $|m_v(x, y)|$, число единодушных пар (3:0) и доля транзитивных троек у отдельного голосующего.

Согласие о руководителе U и L

Пара единодушна, если все три голосующих решили её одинаково. Для запуска k положим

$$U_k = \sum_{\{x,y\}\subset\mathcal{A}} \mathbf{1}[\operatorname{sgn} m_v(x,y) \text{ одинаков при всех } v \notin \{x,y\},\ m_v(x,y) \neq 0], \qquad 0 \le U_k \le 10,$$

а U — среднее U_k по запускам условия.

Нулевая гипотеза для U. Предпочтения голосующих — независимые равномерно случайные порядки, поэтому $\mathbb{E}U_k = 10/4$. Значение p одностороннее, $M = 20000$.

Пусть Λ_k — агенты с наибольшим числом побед в запуске k. Лидер получает долю $1/|\Lambda_k|$, поэтому равенство побед не решается именем агента. Сумма долей самого частого лидера равна

$$L = \max_{a\in\mathcal{A}} \sum_k \frac{\mathbf{1}[a \in \Lambda_k]}{|\Lambda_k|}.$$

Нулевая гипотеза для L. Имена агентов независимо переставляются внутри каждого запуска. Значение p одностороннее, $M = 20000$.

Взаимность τ^{rec}

Каждой паре агентов $\{i, j\}$ сопоставим точку $(\pi_i(j), \pi_j(i))$. По 10 точкам считается

$$\tau^{\text{rec}} = \binom{10}{2}^{-1} (\#\text{согласных пар точек} - \#\text{несогласных пар точек}),$$

причём пары точек с равной координатой не входят в разность.

Первая нулевая гипотеза. Порядки голосующих независимы и равномерно случайны.

Вторая нулевая гипотеза: общие предпочтения. Оценка раскладывается на популярность кандидата и остаток:

$$s_v(x) = \bar{s}(x) + \varepsilon_v(x), \qquad \bar{s}(x) = \frac{1}{4} \sum_{v \neq x} s_v(x),$$

где $\bar{s}(x)$ — популярность, а $\varepsilon_v(x)$ — остаток. Остатки перемешиваются по всем парам (v, x), что сохраняет популярность и разброс, но разрушает связь внутри пар. Общие предпочтения сами дают $\tau^{\text{rec}} > 0$, поэтому одностороннее p считается против этой гипотезы, $M = 2000$.

Следование за точностью τ^{acc}

Пусть $r(x)$ — раунд, который организовал агент x. Его ошибка равна $e(x) = \text{MASE}_{r(x)}$. С поправкой на трудность окна из неё вычитается среднее значение MASE того же окна по запускам условия.

Пусть E_v — порядок агентов $\mathcal{A} \setminus \{v\}$ по возрастанию e. Тогда

$$\tau^{\text{acc}} = \frac{1}{5} \sum_{v \in \mathcal{A}} \tau(\pi_v, E_v), \qquad H = \sum_{v \in \mathcal{A}} \mathbf{1}\Big[\pi_v^{-1}(1) = \arg\min_{x \neq v} e(x)\Big].$$

H — число голосующих, поставивших первым самого точного; случайный уровень для него равен $1/4$ на голосующего. Отдельно считается, совпал ли победитель голосования с самым точным организатором (случайный уровень $1/5$ на запуск).

Нулевая гипотеза. Ошибки перемешиваются между агентами внутри запуска, поскольку голоса внутри запуска зависимы. Значения p односторонние, $M = 2000$.

Согласие с судьёй τ^{J}

Судья работает после голосования в отдельных запросах. Он не знает, кто был организатором, и не видит реальных значений, а агентам его оценки не передаются. Всего в запуске 25 запросов.

Шкала от 1 до 5	Что оценивает	Число оценок
`allocation`	распределение ролей организатором	5
`role_fit`	соответствие ответа роли и заданию	20
`usefulness`	польза ответа для прогноза	20

Пусть J_v — порядок организаторов $\mathcal{A} \setminus \{v\}$ по убыванию `allocation`. Тогда

$$\tau_v^{\mathsf{J}} = \tau(\pi_v, J_v).$$

Для группы так же сравнивается порядок по числу побед $w(x)$, введённому на слайде о порядке голосов. Если все оценки запуска равны, порядка нет и значение не определено. По условию τ_v^{J} усредняется, а нулевая гипотеза перемешивает оценки между агентами внутри запуска; p одностороннее, $M = 2000$.

Влияние вопроса о причине φ

Голос с причиной даёт для голосующего v и пары $\{x, y\}$ выбор $c_v(x, y) \in \{x, y\}$. Пусть $\mathcal{P}$ — множество упорядоченных так троек (v, x, y), что перевес голоса цифрой $m_v(x, y) > 0$. Доля изменившихся пар равна

$$\varphi = \frac{1}{|\mathcal{P}|} \sum_{(v,x,y)\in\mathcal{P}} \mathbf{1}[c_v(x, y) = y].$$

Порядок голосующего в голосе с причиной π'_v строится по числу выборов, а при равенстве — по сумме перевесов. Сходство с голосом цифрой равно $\tau(\pi_v, \pi'_v)$.

Устойчивость. В пробе с пятью вызовами на пару совпадение всех пяти выборов сравнивается с $|m_v(x, y)|$. Причина пишется после выбора, поэтому мотивом выбора не считается.